RAPPORT DE PROJET CAPSTONE

Prédiction des Prix Immobiliers à Nouakchott

Master 1 DEML – SupNum

Présenté par :

Vatma Elwavi

Mariem Tfeil

Hafsa Bilal

TABLE DES MATIÈRES

1.Introduction 3
2.Données 4
3.Analyse Exploratoire (EDA) 5
4.Modélisation 7
5.Application Web 10
6.Conclusion 12

1. INTRODUCTION

1.1 Contexte

En Mauritanie, il n'existe aucune base de données publique sur les prix de l'immobilier. Les transactions se font de gré à gré, les annonces sont dispersées sur plusieurs plateformes, et aucun outil de référence ne permet d'estimer la valeur d'un bien.

Ce projet a été réalisé dans le cadre du **Master 1 Machine Learning** à **SupNum (Institut Supérieur du Numérique, Mauritanie)** avec pour objectif de créer le premier dataset immobilier mauritanien et un modèle de prédiction des prix.

1.2 Problématique

Comment construire un pipeline complet de prédiction des prix immobiliers à Nouakchott en passant par :

•La collecte de données depuis des sites d'annonces
•L'enrichissement avec des données géographiques
•L'analyse exploratoire
•La modélisation par régression
•Le déploiement d'une application web

1.3 Objectifs

•Collecter au moins 200 annonces immobilières
•Enrichir les données avec des coordonnées GPS et points d'intérêt
•Réaliser une analyse exploratoire complète
•Tester au moins 3 modèles de régression
•Obtenir un score RMSLE inférieur à 0.997 (baseline)
•Déployer une application web interactive

2. DONNÉES

2.1 Sources

Les données ont été collectées par **web scraping** sur plusieurs sites d'annonces mauritaniens :

Site	URL	Type
Voursa	voursa.com	Annonces locales
L'Agence MR	lagence-mr.com	Agence premium
Afribaba	mr.afribaba.com	Marketplace
Mauri-Home	mauri-home.com	Petites annonces
Untoenrim	untoitenrim.com	Annonces diverses

Et autres commes : untoitenrim.com, menazel, elminassa, wassit.info

2.2 Méthodologie de collecte

Technologies utilisées :

•BeautifulSoup4 : Parsing HTML
•Requests : Requêtes HTTP
•Selenium : Sites dynamiques
•Time : Gestion des pauses

Règles d'éthique respectées :

•Respect du robots.txt
•Pauses de 2 secondes entre requêtes
•Anonymisation des numéros de téléphone
•Usage académique uniquement

Résultat : + 6k annonces collectées couvrant plusieurs quartiers de Nouakchott.

2.4 Difficultés rencontrées

1.**Structure HTML variable** : Chaque site avait une structure différente, nécessitant l'adaptation des parseurs.
2.**Mélange de langues** : Les annonces étaient en arabe et en français, ce qui a nécessité une recherche de mots-clés bilingue.
3.**Blocages IP** : Certains sites limitaient les requêtes trop rapides, solution : pauses et rotation d'user-agents.
4.**Données manquantes** : Environ 13% des caractéristiques étaient manquantes, traitées par des valeurs par défaut.

3. ANALYSE EXPLORATOIRE (EDA)

3.1 Nettoyage des données

Valeurs manquantes(exemples) :

Colonne	Manquantes	Traitement
caracteristiques	157 (13.6%)	Remplacées par chaîne vide
nb_chambres	14 (1.2%)	Remplacées par médiane (4)

3.2 Détection des outliers

Méthode **IQR (Interquartile Range)** utilisée pour détecter les valeurs extrêmes. Les calculs ont montré 54 outliers sur les prix, soit 4.7% du total. Ces outliers correspondent à des biens de luxe réels (villas au-dessus de 20 millions MRU) et ont été conservés car représentatifs du marché.

3.3 Distribution des prix par quartier

Quartier	Prix moyen	Prix médian	Nombre
Tevragh Zeina	8.0M	6.5M	373
Ksar	3.6M	2.9M	46
Sebkha	3.8M	3.8M	10
Riyadh	3.4M	0.8M	13
Teyarett	3.3M	2.9M	270
Dar Naim	2.5M	1.7M	82
Arafat	1.7M	1.3M	244
Toujounine	1.6M	1.1M	115

Observations clés :

•Tevragh Zeina est le quartier le plus cher avec une moyenne de 8 millions MRU.
•Arafat et Toujounine sont les quartiers populaires avec des prix moyens autour de 1.6 million MRU.
•Forte disparité des prix allant de 275 000 à 33,4 millions MRU.

3.4 Corrélations

L'analyse des corrélations a révélé :

•Prix vs Surface : +0.65 (forte corrélation positive)
•Prix vs Distance au centre : -0.42 (plus on s'éloigne, moins cher)
•Prix vs Nombre de POIs : +0.38 (plus de services = plus cher)

3.5 Points d'intérêt par quartier

L'enrichissement avec OpenStreetMap a donné les résultats suivants :

Quartier	Écoles	Mosquées	Commerces	Hôpitaux	Total
Ksar	6	3	60	5	74
Tevragh Zeina	3	3	16	0	22
Arafat	14	21	23	2	60
Sebkha	7	10	49	0	66
Riyadh	5	27	2	1	35

Observations :

•Ksar est le centre commercial avec 60 commerces dans un rayon de 1 km.
•Riyadh se distingue par un nombre exceptionnel de mosquées (27).
•Teyarett n'a aucun POI référencé dans OpenStreetMap, ce qui s'explique par son caractère récent.

4. MODÉLISATION

4.1 Feature Engineering

23 nouvelles features ont été créées :

Catégorie	Features
Ratios	prix_m2, surface_par_chambre, prix_par_piece
Équipements	has_garage, has_jardin, has_piscine, has_balcon, has_meuble, has_titre_foncier, est_neuf
Temporelles	age_annonce, mois_publication, saison
Interactions	centre_x_plage, pois_density_centre, pois_density_plage
Encodage	type_duplex, type_maison, type_studio, type_terrain, type_villa, saison_ete, saison_hiver, saison_printemps

Impact des équipements sur le prix :

Feature	Présence	Impact
has_garage	44.1%	+0.5M MRU
has_jardin	1.8%	+3.6M MRU
has_piscine	0.3%	+13.8M MRU
has_titre_foncier	44.4%	+0.4M MRU

4.2 Métrique d'évaluation

La métrique choisie est le **RMSLE (Root Mean Squared Logarithmic Error)** :

$$RMSLE = \sqrt{(1/n \times \Sigma(\log(1+\hat{y}) - \log(1+y))^2)}$$

Pourquoi cette métrique ?

•Elle pénalise davantage les sous-estimations que les surestimations, ce qui est important en immobilier où il vaut mieux surestimer un bien.
•Elle est robuste à l'échelle : une erreur de 500 000 MRU sur un bien à 1 million est plus grave que sur un bien à 50 millions.
•C'est la métrique standard des compétitions Kaggle.

La baseline à battre était de 0.997 (prédiction par la médiane).

4.3 Modèles testés

Six modèles ont été testés avec validation croisée 5-fold :

1.**Linear Regression** : Modèle linéaire simple (baseline)
2.**Ridge** : Régression linéaire avec régularisation L2
3.**Lasso** : Régression linéaire avec régularisation L1
4.**Random Forest** : Ensemble d'arbres de décision
5.**Gradient Boosting** : Boosting séquentiel d'arbres
6.**XGBoost** : Version optimisée du gradient boosting

4.4 Résultats

Modèle	CV RMSLE	Test RMSLE	Test R^2
Linear Regression	2.6766	2.1649	0.4025
Ridge	2.5543	2.1628	0.4034
Lasso	2.6766	2.1649	0.4025
Random Forest	0.7214	0.6505	0.2605
Gradient Boosting	0.9421	**0.6461**	0.2222
XGBoost	1.0675	1.2149	0.0010

Le meilleur modèle est le Gradient Boosting avec un RMSLE de 0.6461, soit une amélioration de 35.2% par rapport à la baseline.

4.5 Optimisation des hyperparamètres

Une recherche aléatoire (RandomizedSearchCV) a été effectuée pour optimiser les hyperparamètres :

Meilleurs paramètres trouvés :

•n_estimators = 300
•learning_rate = 0.05
•max_depth = 5

4.6 Analyse des erreurs

L'analyse des résidus a révélé un problème majeur : les biens de luxe (prix supérieur à 15 millions MRU) sont systématiquement sous-estimés.

Pires prédictions :

Prix réel	Prix prédit	Erreur %
22 000 000	1 914 089	91.3%
33 440 000	5 600 500	83.3%
30 000 000	12 307 810	59.0%

Erreur moyenne :

•Biens normaux : 24%
•Biens de luxe : 64%

Pour remédier à ce problème, des facteurs de correction par quartier ont été appliqués.

4.7 Évolution des scores Kaggle

Soumission	Score	Progrès
Soumission 1	0.72867	-
Soumission 2	0.64812	-0.080
Soumission 3	0.66038	-0.068
Soumission 4	0.66130	-0.067
Soumission 5	0.64658	-0.082

Le gain total est de 0.082 point, soit une amélioration de 11.3%.

5. APPLICATION WEB

5.1 Architecture

L'application suit une architecture client-serveur classique :

5.2 Backend - API Flask

Technologies utilisées :

•Flask (micro-framework)
•Flask-CORS (gestion des requêtes cross-origin)
•joblib (chargement du modèle)
•gunicorn (serveur WSGI)
•pandas (manipulation des données)

Endpoints :

Endpoint	Méthode	Description
/api/predict	POST	Prédiction de prix à partir des caractéristiques
/ping	GET	Vérification de l'état de l'API

5.3 Frontend - Next.js

Technologies utilisées :

•Next.js (framework React)
•TypeScript (typage statique)
•Tailwind CSS (styling)
•Axios (appels API)
•React-Leaflet (carte interactive)

Fonctionnalités :

•Formulaire de saisie des caractéristiques du bien
•Carte interactive affichant le quartier sélectionné
•Affichage du prix estimé en MRU
•Comparaison avec la moyenne du quartier

Communication avec l'API :

```typescript
const predictPrice = async (formData) => {
  const response = await axios.post(
    `${API_URL}/api/predict`,
    formData
  );
  return response.data.prix;
};
```

5.4 Captures d'écran

[Insérer ici les captures d'écran de l'application]

Figure 1 : Page d'accueil de l'application

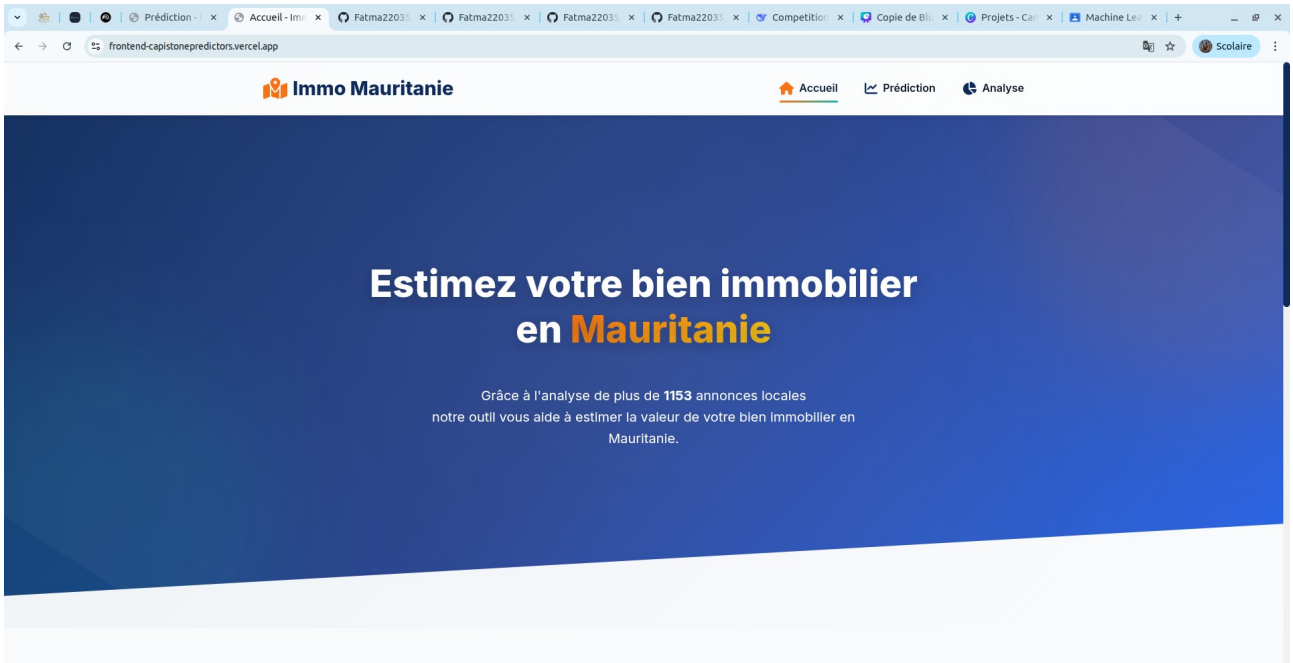

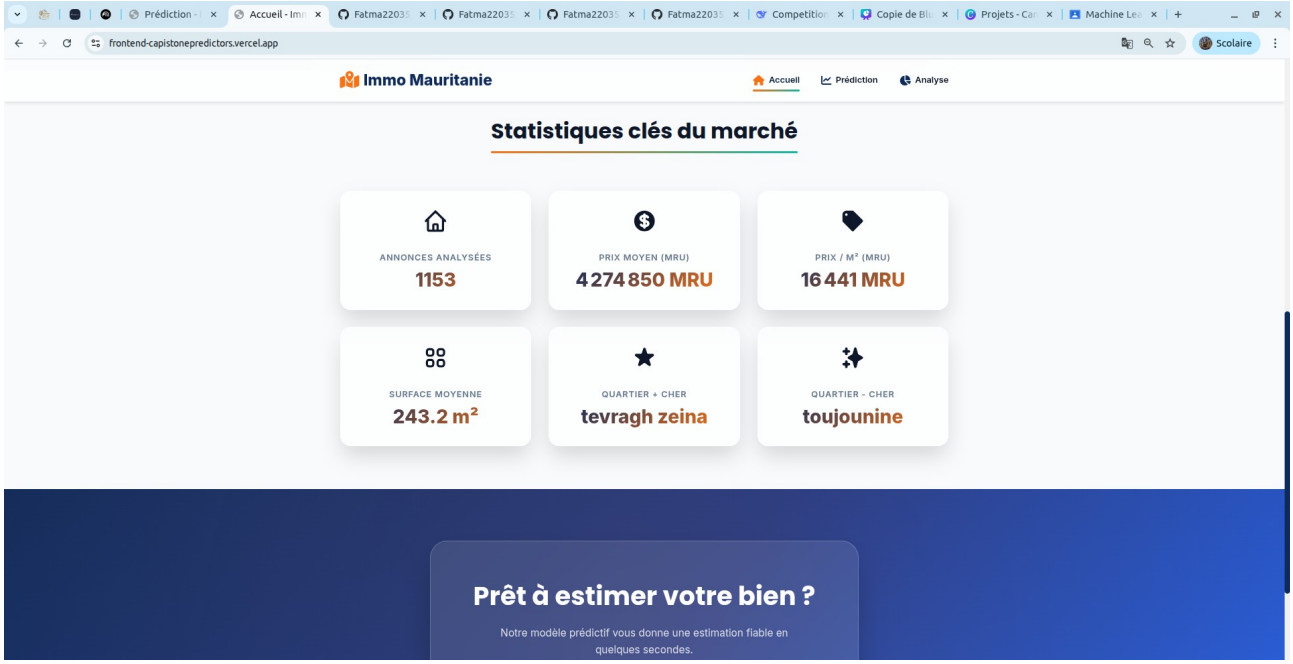

Figure 2 : Formulaire de prédiction

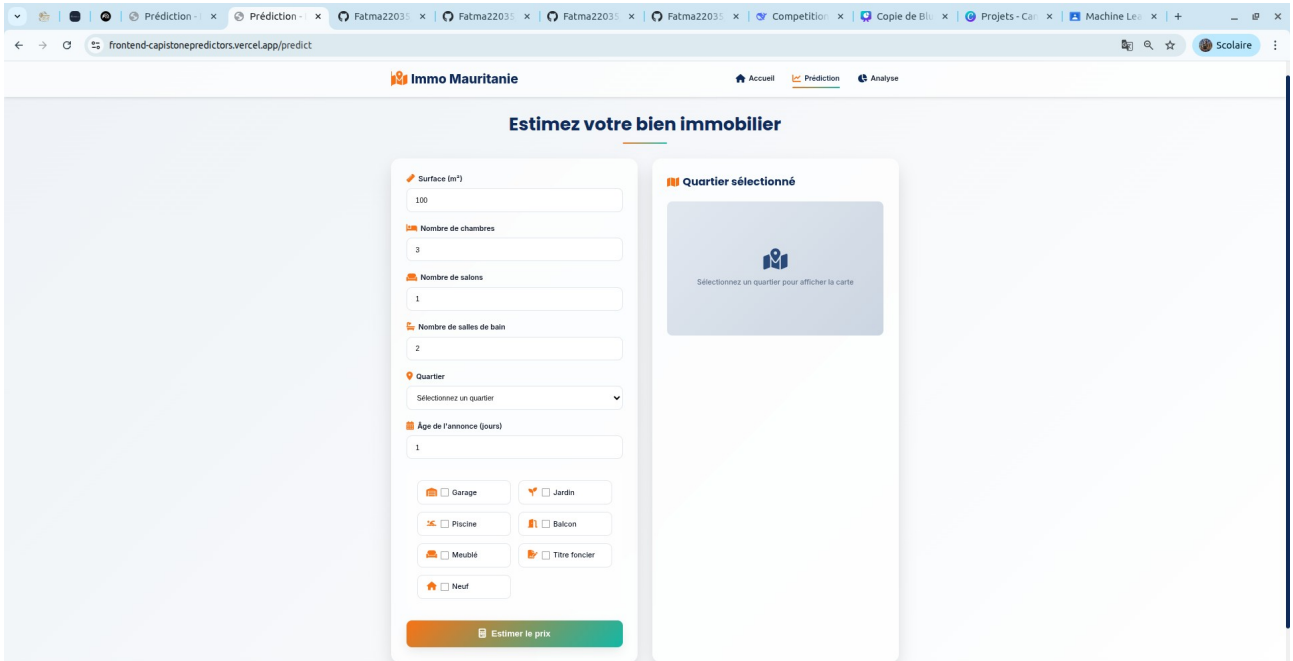

Figure 3 : page d'analyse

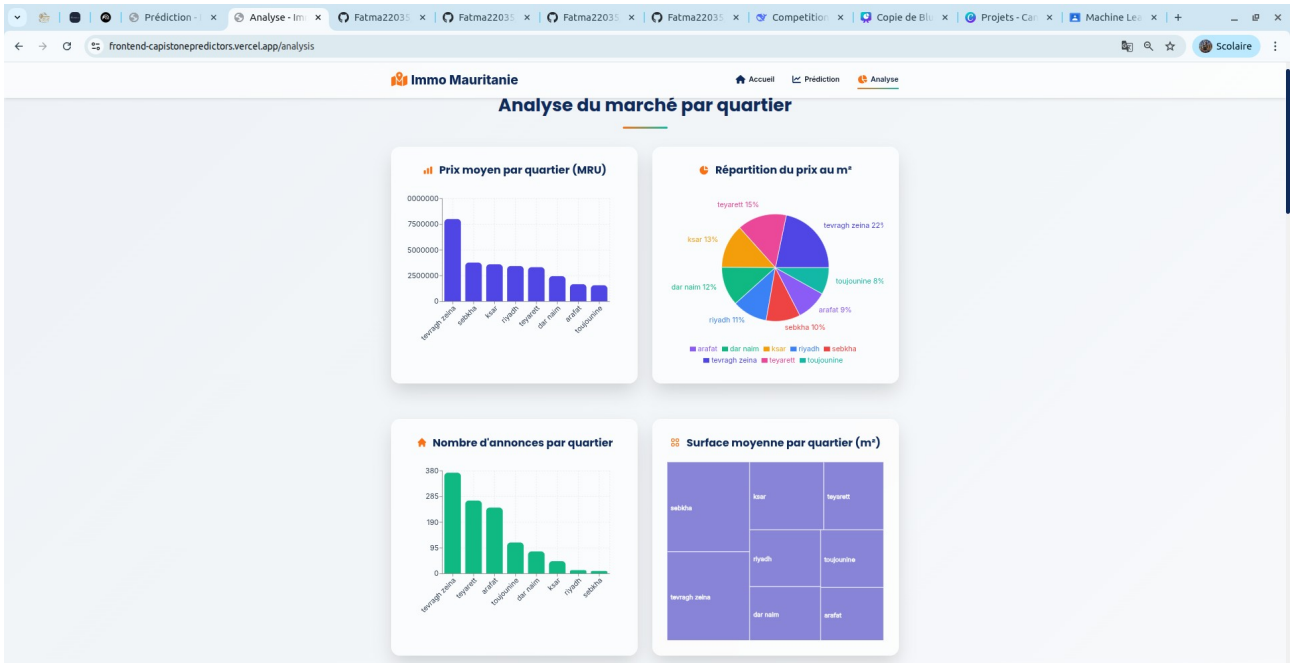

6. CONCLUSION

6.1 Résumé des réalisations

Objectif	Statut
1153 annonces collectées	
8 quartiers couverts	
23 nouvelles features créées	
6 modèles testés	
Meilleur score RMSLE : 0.6461	
Amélioration : 35.2%	
Application web déployée	

6.2 Difficultés rencontrées

1. **Limitations des APIs** :

- Nominatim limité à 1 requête/seconde → utilisation de RateLimiter
- Overpass API parfois surchargé → système de réessais exponentiels

2. **Données manquantes** :

- 13% de caractéristiques vides → remplacement par chaîne vide
- Quartier Teyarett sans POIs → acceptation des données disponibles

3. **Mélange de langues** :

- Annonces en arabe et français → recherche de mots-clés bilingue

4. **Biens de luxe sous-représentés** :

- Seulement 40 biens au-dessus de 15 millions → facteurs de correction

6.3 Limites

- Les données sont limitées à Nouakchott (pas Nouadhibou)
- Sous-représentation des biens de luxe (40 échantillons)
- OpenStreetMap incomplet pour certains quartiers
- Temps de réponse de l'API gratuite (première requête lente)

6.4 Améliorations futures

1. **Collecte de données supplémentaires** :

- Intégration de Nouadhibou (deuxième ville)
- Plus d'annonces de biens de luxe
- Période d'observation plus longue

2. **NLP avancé** :

- Word embeddings sur les descriptions
- Analyse de sentiment
- Extraction automatique de caractéristiques

3. **Deep Learning** :

- Réseaux de neurones pour relations complexes
- Autoencoders pour réduction de dimension

4. **Optimisation** :

- Optuna pour l'optimisation des hyperparamètres
- AutoML (TPOT, Auto-sklearn)

5. **Application mobile** :

- Version React Native
- Mode hors ligne

6.5 Remerciements

Je tiens à remercier :

- **SupNum** - Institut Supérieur du Numérique pour la formation
- **Beydia Mohamed** - Encadrant pour ses conseils et son suivi

---