وزارة التعليم العالي والبحث العلمي
المعهد العالي للرقمنة
Ministère de l'Enseignement Supérieur
et de la Recherche Scientifique
Institut Supérieur du Numérique

الجمهورية الإسلامية الموريتانية
شرف - إخاء - عدل
République Islamique de Mauritanie
Honneur - Fraternité - Justice

RAPPORT DE PROJET CAPSTONE

Sous thème :

Prediction des Prix Immobiliers en Mauritanie

Réalisé par :

Mareim Mohamed Tfeil (22087)
Vatma El wavi(22035)
Hafsa bilal (22067)

Remerciements

Je tiens à exprimer ma profonde gratitude envers toutes les personnes et institutions qui ont contribué à la réalisation de ce projet.

Je remercie tout d'abord SupNum - Institut Supérieur du Numérique pour la qualité de la formation dispensée, ainsi que pour l'environnement académique stimulant qui m'a permis de développer mes compétences en Machine Learning et en Data Science.

Mes sincères remerciements s'adressent également à Monsieur Beydia Mohamed, mon professeur , pour son accompagnement, ses conseils précieux, sa disponibilité et son suivi tout au long de ce projet. Ses orientations ont été déterminantes dans la réussite de ce travail.

Table des matières

1 Introduction....4
Contexte....4
Problématique....4
2 Objectif Général du Projet....5
....5
Chapitre 1 : Web Scraping & Collecte....6
Méthodologie de Collecte des Données....6
Chapitre 2 : ENRICHISSEMENT GÉOSPATIAL....8
Géocodage avec Nominatim (OpenStreetMap)....8
Enrichissement via Overpass API....9
Features Géographiques Crées....9
Chapitre 3 : ANALYSE EXPLORATOIRE DES DONNÉES (EDA)....10
Nettoyage des données....10
Détection des outliers....10
des prix par quartier....11
Corrélations....11
....12
chapitre 4 : MODÉLISATION ET PRÉDICTION....13
Feature Engineering....13
Métrique d'évaluation....14
Modèles testés....14
Optimisation des hyperparamètres....15
Analyse des erreurs :....15
chapitre 5: Application Web....16
Architecture....16
Backend - API Flask....17
Frontend - Next.js....17
CONCLUSION....20
Résumé des réalisations....20
Difficultés rencontrées....21
Limites....21
Améliorations futures....22

1 Introduction

Contexte

En Mauritanie, il n'existe pas de base de données publique fiable sur les prix de l'immobilier. Les transactions se font généralement de gré à gré, tandis que les annonces sont dispersées sur plusieurs plateformes, rendant difficile l'accès à une information claire et structurée.

Dans ce contexte, il n'existe aucun outil de référence permettant d'estimer la valeur réelle d'un bien immobilier.

Ce projet s'inscrit dans le cadre du Master 1 en Machine Learning à SupNum (Institut Supérieur du Numérique, Mauritanie). Il vise à construire un dataset immobilier mauritanien et à développer un modèle capable de prédire les prix des biens immobiliers.

Problématique

La problématique principale de ce projet est la suivante :

Comment concevoir un pipeline complet de prédiction des prix immobiliers à Nouakchott ?

Pour répondre à cette question, plusieurs étapes sont nécessaires :

- Collecter les données à partir de différentes plateformes d'annonces immobilières
- Enrichir ces données avec des informations géographiques
- Réaliser une analyse exploratoire pour comprendre les données
- Construire un modèle de régression pour prédire les prix

2 Objectif Général du Projet

Construire le premier système complet de prédiction des prix immobiliers à Nouakchott en développant un pipeline intégré de data science — allant de la collecte de données par web scraping à l'enrichissement géospatial, en passant par l'analyse exploratoire, la modélisation prédictive et le déploiement d'une application web interactive — afin de répondre à l'absence totale d'outils d'estimation immobilière en Mauritanie et de fournir une solution concrète, accessible et fiable aux particuliers, professionnels et chercheurs.

- Collecter au moins 200 annonces immobilières
- Enrichir les données avec des coordonnées GPS et points d'intérêt
- Réaliser une analyse exploratoire complète
- Tester au moins 3 modèles de régression
- Obtenir un score RMSLE inférieur à 0.997 (baseline)
- Déployer une application web interactive

Chapitre 1 : Web Scraping & Collecte

Sources a scraper

Les données ont été collectées par web scraping sur plusieurs sites d'annonces mauritaniens :

Sources scrapées (9)

- voursa.com
- lagence-mr.com
- afribaba.com
- mauri-home.com
- untoitenrim.com
- menazel.org
- elminassa.com
- wassit.info
- https://www.elminassa.com/app.html?v=20250405

Méthodologie de Collecte des Données

- Technologies utilisées :
- BeautifulSoup4 : Parsing HTML
- Requests : Requêtes HTTP
- Selenium : Sites dynamiques
- Time : Gestion des pauses Règles d'éthique respectées :
- Respect du robots.txt
- Pauses de 2 secondes entre requêtes
- Anonymisation des numéros de téléphone
- Usage académique uniquement

Résultat : + 6k annonces collectées couvrant plusieurs quartiers de Nouakchott.

Difficultés rencontrées

Structure HTML variable : Chaque site avait une structure différente, nécessitant l'adaptation des parseurs.

Mélange de langues : Les annonces étaient en arabe et en français, ce qui a nécessité une recherche de mots-clés bilingue.

Blocages IP : Certains sites limitaient les requêtes trop rapides, solution : pauses et rotation d'user-agents.

Données manquantes : Environ 13% des caractéristiques étaient manquantes, traitées par des valeurs par défaut.

Chapitre 2 : ENRICHISSEMENT GÉOSPATIAL

Transformer des adresses textuelles ("Tevragh Zeina, près de l'ambassade") en données géographiques exploitables est une étape cruciale pour améliorer la prédiction.

Géocodage avec Nominatim (OpenStreetMap)

Nous avons utilisé la librairie geopy pour convertir les noms de quartiers en coordonnées GPS via l'API gratuite Nominatim.

M	N	O	P
quartier_encode	log_prix	latitude	longitude
1676908.196721	14.40329777842	18.0459512	-15.9632837
8013969.436997	14.40329777842	18.1111443	-16.0038402
3330685.925925	13.71015115341	18.1591445	-15.9271893
3330685.925925	14.28551481220	18.1591445	-15.9271893
1571960.0	13.59236825664	18.0724322	-15.9099003
3330685.925925	15.42494867039	18.1591445	-15.9271893
3330685.925925	14.64842011568	18.1591445	-15.9271893
8013969.436997	15.68731288871	18.1111443	-16.0038402

Enrichissement via Overpass API

L'API Overpass permet de récupérer les Points d'Intérêt (POI) autour d'un point GPS depuis la base de données OpenStreetMap.

Features Géographiques Crées

R	S	T	U	V	W	X	Y	
dist_centre_ville	dist_aeroport_kr	dist_plage_km	nb_ecoles_1km	nb_mosquees_1	nb_commerce_1	nb_hopitaux_1kr	nb_total_pois_1k	p
6.55586954657(	7.209088782152	6.50658307406	14	21	23	2	60	1
4.225776690673	5.87382342865(	4.641185531091	3	3	16	0	22	6
7.200246788349	5.984872496035	13.69126347964	0	0	0	0	0	4
7.200246788349	5.984872496035	13.69126347964	0	0	0	0	0	1
6.798401097987	5.760954844879	11.48021623371	6	5	4	1	16	4
7.200246788349	5.984872496035	13.69126347964	0	0	0	0	0	9
7.200246788349	5.984872496035	13.69126347964	0	0	0	0	0	1

Chapitre 3 : ANALYSE EXPLORATOIRE DES DONNÉES (EDA)

Nettoyage des données

Valeurs manquantes(exemples) :

Colonne	Manquantes	Traitement
caracteristiques	157 (13.6%)	Remplacées par chaîne vide
nb_chambres	14 (1.2%)	Remplacées par médiane (4)

Détection des outliers

Méthode IQR (Interquartile Range) utilisée pour détecter les valeurs extrêmes. Les calculs ont montré 54 outliers sur les prix, soit 4.7% du total. Ces outliers correspondent à des biens de luxe réels (villas au-dessus de 20 millions MRU) et ont été conservés car représentatifs du marché.

des prix par quartier

Quartier	Prix moyen	Prix médian	Nombre
Tevragh Zeina	8.0M	6.5M	373
Ksar	3.6M	2.9M	46
Sebkha	3.8M	3.8M	10
Riyadh	3.4M	0.8M	13
Teyarett	3.3M	2.9M	270
Dar Naim	2.5M	1.7M	82
Arafat	1.7M	1.3M	244
Toujounine	1.6M	1.1M	115

Observations clés :

- Tevragh Zeina est le quartier le plus cher avec une moyenne de 8 millions MRU. Arafat et Toujounine sont les quartiers populaires avec des prix moyens autour de 1.6 million MRU.
- Forte disparité des prix allant de 275 000 à 33,4 millions MRU.

Corrélations

L'analyse des corrélations a révélé :

- Prix vs Surface : +0.65 (forte corrélation positive)
- Prix vs Distance au centre : -0.42 (plus on s'éloigne, moins cher)
- Prix vs Nombre de POIs : +0.38 (plus de services = plus cher)

Points d'intérêt par quartier

L'enrichissement avec OpenStreetMap a donné les résultats suivants :

Quartier	Écoles	Mosquées	Commerces	Hôpitaux	Total
Ksar	6	3	60	5	74
Tevragh Zeina	3	3	16	0	22
Arafat	14	21	23	2	60
Sebkha	7	10	49	0	66
Riyadh	5	27	2	1	35

Observations :

- Ksar est le centre commercial avec 60 commerces dans un rayon de 1 km. •Riyadh se distingue par un nombre exceptionnel de mosquées (27).
- Teyarett n'a aucun POI référencé dans OpenStreetMap, ce qui s'explique par son caractère récent.

chapitre 4 : MODÉLISATION ET PRÉDICTION

Feature Engineering

nouvelles features ont été créées :

Catégorie	Features
Ratios	prix_m2, surface_par_chambre, prix_par_piece
Équipements	has_garage, has_jardin, has_piscine, has_balcon, has_meuble, has_titre_foncier, est_neuf
Temporelles	age_annonce, mois_publication, saison
Interactions	centre_x_plage, pois_density_centre, pois_density_plage
Encodage	type_duplex, type_maison, type_studio, type_terrain, type_villa, saison_ete, saison_hiver, saison_printemps

Impact des équipements sur le prix :

Feature	Présence	Impact
has_garage	44.1%	+0.5M MRU
has_jardin	1.8%	+3.6M MRU
has_piscine	0.3%	+13.8M MRU
has_titre_foncier	44.4%	+0.4M MRU

Métrique d'évaluation

La métrique choisie est le RMSLE (Root Mean Squared Logarithmic Error) :

$$RMSLE = \sqrt{(1/n \times \Sigma(\log(1+\hat{y}) - \log(1+y))^2)}$$

Pourquoi cette métrique ?

- Elle pénalise davantage les sous-estimations que les surestimations, ce qui est important en immobilier où il vaut mieux surestimer un bien.
- Elle est robuste à l'échelle : une erreur de 500 000 MRU sur un bien à 1 million est plus grave que sur un bien à 50 millions.
- C'est la métrique standard des compétitions Kaggle. La baseline à battre était de 0.997 (prédiction par la médiane

Modèles testés

Six modèles ont été testés avec validation croisée 5-fold :

- Linear Regression : Modèle linéaire simple (baseline)
- Ridge : Régression linéaire avec régularisation L2
- Lasso : Régression linéaire avec régularisation L1
- Random Forest : Ensemble d'arbres de décision
- Gradient Boosting : Boosting séquentiel d'arbres 6.XGBoost : Version optimisée du gradient boosting

Résultats :

Modèle	CV RMSLE	Test RMSLE	Test R^2
Linear Regression	2.6766	2.1649	0.4025
Ridge	2.5543	2.1628	0.4034
Lasso	2.6766	2.1649	0.4025
Random Forest	0.7214	0.6505	0.2605
Gradient Boosting	0.9421	**0.6461**	0.2222
XGBoost	1.0675	1.2149	0.0010

Le meilleur modèle est le Gradient Boosting avec un RMSLE de 0.6461, soit une amélioration de 35.2% par rapport à la baseline.

Optimisation des hyperparamètres

Une recherche aléatoire (RandomizedSearchCV) a été effectuée pour optimiser les hyperparamètres

Meilleurs paramètres trouvés :

•n_estimators = 300

•learning_rate = 0.05

•max_depth = 5

Analyse des erreurs :

L'analyse des résidus a révélé un problème majeur : les biens de luxe (prix supérieur à 15 millions MRU) sont systématiquement sous-estimés.

Pires prédictions :

Prix réel	Prix prédit	Erreur %
22 000 000	1 914 089	91.3%
33 440 000	5 600 500	83.3%
30 000 000	12 307 810	59.0%

Erreur moyenne :

•Biens normaux : 24%

•Biens de luxe : 64% Pour remédier à ce problème, des facteurs de correction par quartier ont été appliqués.

chapitre 5: Application Web

Architecture

L'application suit une architecture client-serveur classique :

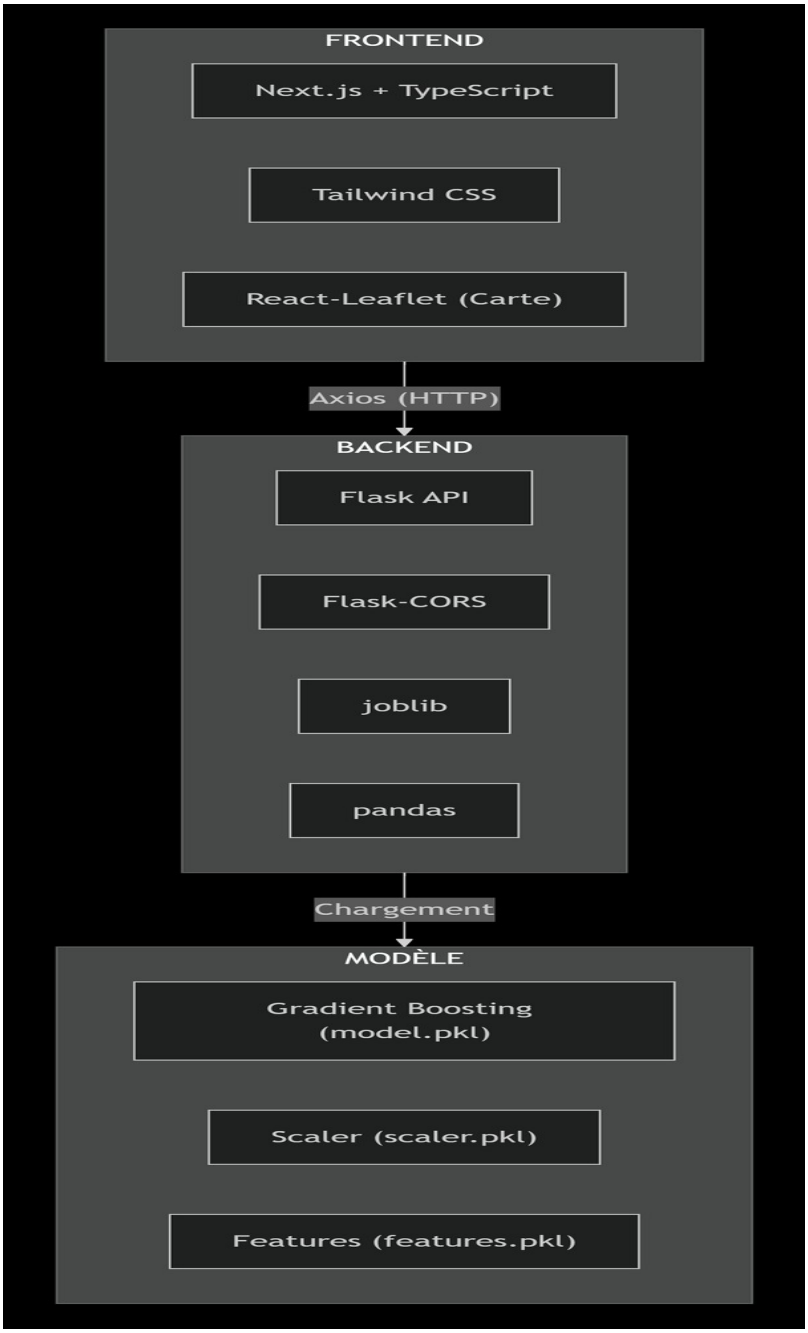

Backend - API Flask

Technologies utilisées :

- Flask (micro-framework)
- Flask-CORS (gestion des requêtes cross-origin)
- joblib (chargement du modèle)
- gunicorn (serveur WSGI)
- pandas (manipulation des données)

Endpoints :

Endpoint	Méthode	Description
/api/predict	POST	Prédiction de prix à partir des caractéristiques
/ping	GET	Vérification de l'état de l'API

Frontend - Next.js

Technologies utilisées :

- Next.js (framework React)
- TypeScript (typage statique)
- Tailwind CSS (styling)
- Axios (appels API)
- React-Leaflet (carte interactive)

Fonctionnalités :

- Formulaire de saisie des caractéristiques du bien
- Carte interactive affichant le quartier sélectionné
- Affichage du prix estimé en MRU
- Comparaison avec la moyenne du quartier

Figures :

Figure 1 : Page d'accueil de l'application

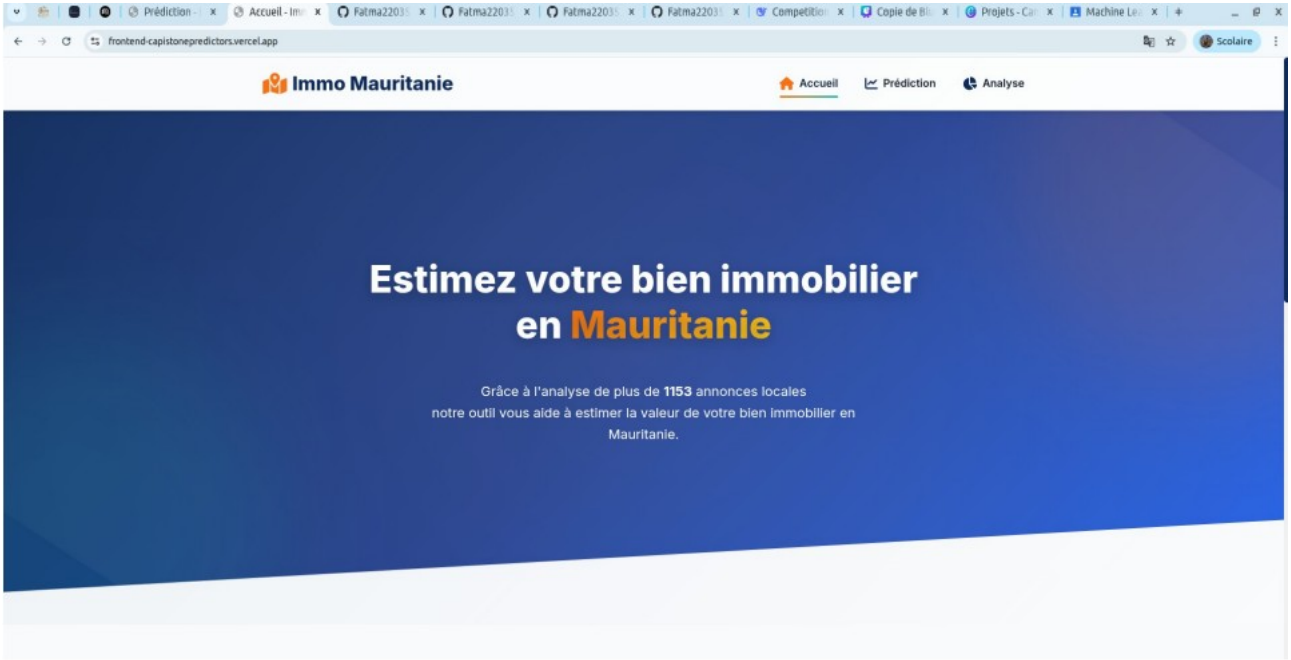

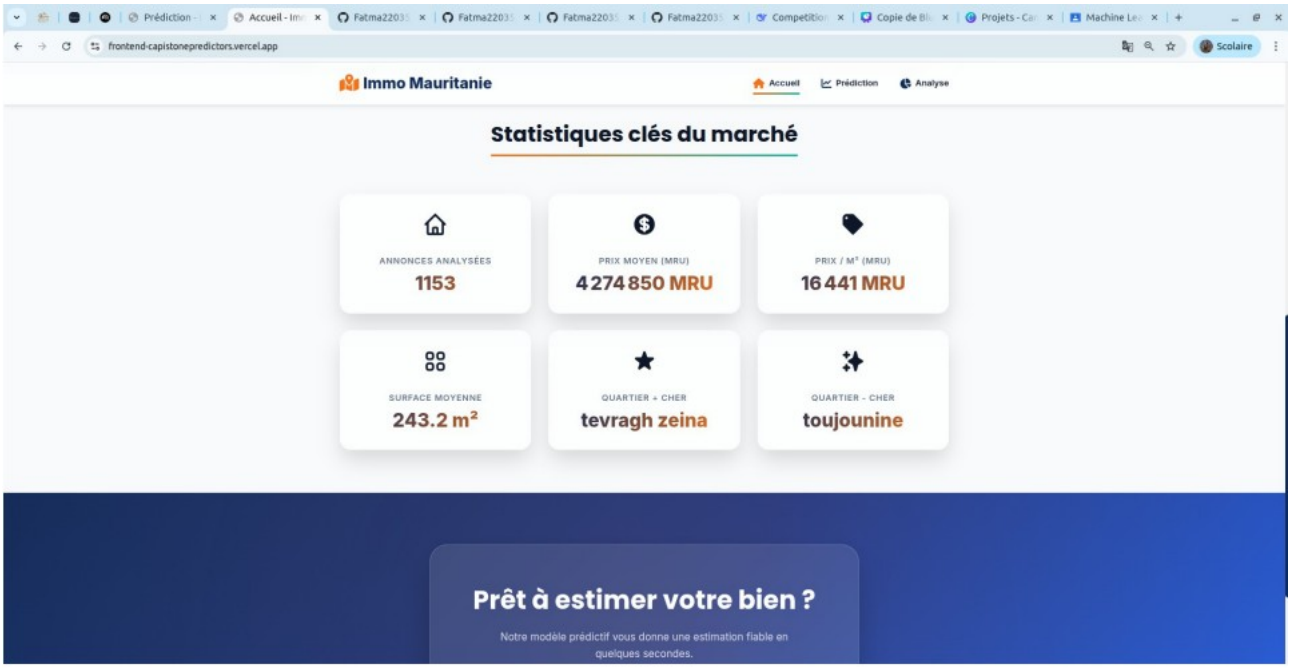

Figure 2 : Formulaire de prédiction

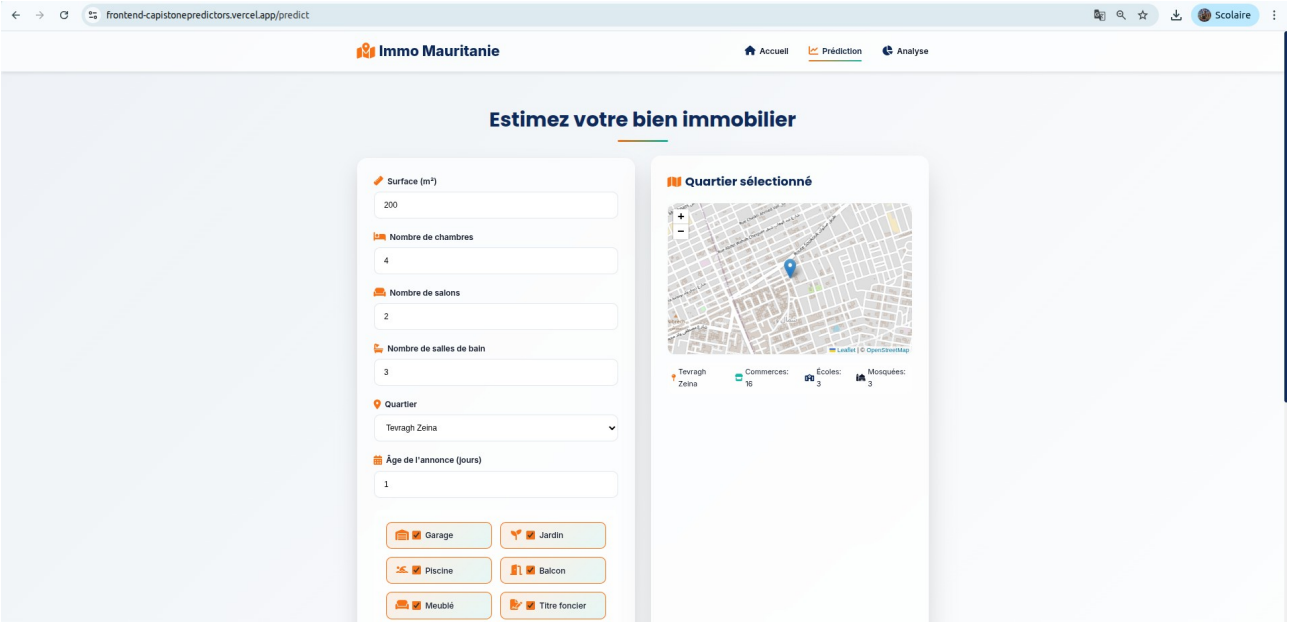

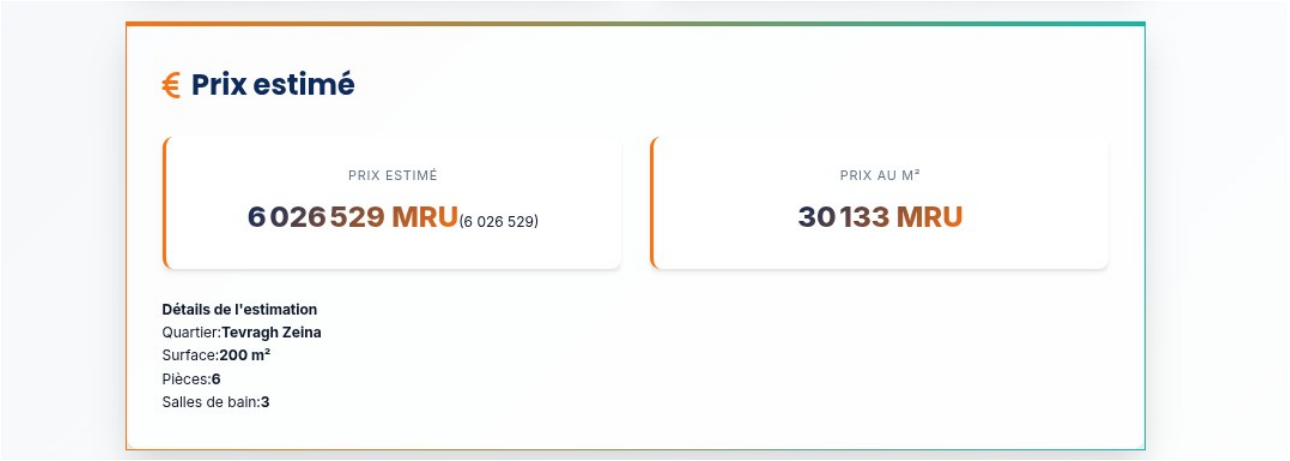

Figure 3 : page d’analyse

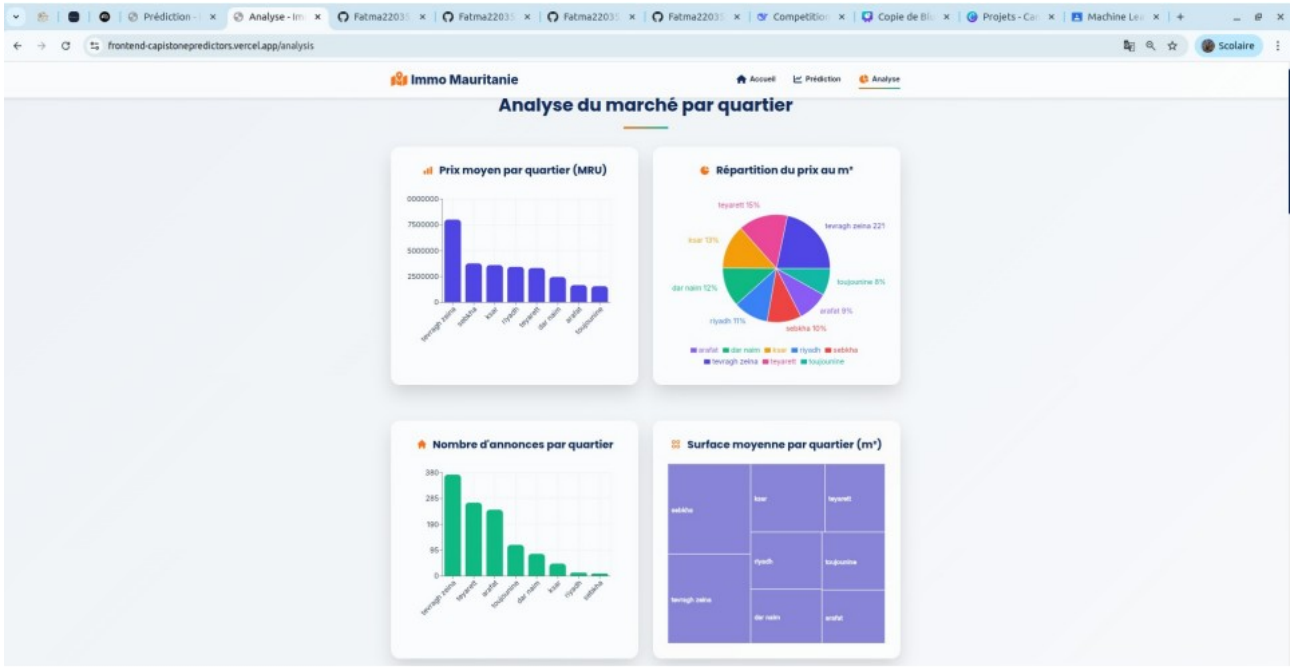

CONCLUSION

Résumé des réalisations

Objectif	Statut
1153 annonces collectées	
8 quartiers couverts	
23 nouvelles features créées	
6 modèles testés	
Meilleur score RMSLE : 0.6461	
Amélioration : 35.2%	
Application web déployée	

Difficultés rencontrées

Limitations des APIs :

- Nominatim limité à 1 requête/seconde → utilisation de RateLimiter
- Overpass API parfois surchargé → système de réessais exponentiels

Données manquantes :

- 13% de caractéristiques vides → remplacement par chaîne vide
- Quartier Teyarett sans POIs → acceptation des données disponibles

Mélange de langues :

- Annonces en arabe et français → recherche de mots-clés bilingue 4. Biens de luxe sous-représentés :
- Seulement 40 biens au-dessus de 15 millions → facteurs de correction

Limites

Les données sont limitées à Nouakchott (pas Nouadhibou)

Sous-représentation des biens de luxe (40 échantillons)

OpenStreetMap incomplet pour certains quartiers

Temps de réponse de l'API gratuite (première requête lente)

Améliorations futures

Collecte de données supplémentaires :

• Intégration de Nouadhibou (deuxième ville)

• Plus d'annonces de biens de luxe

• Période d'observation plus longue 2. NLP avancé :

• Word embeddings sur les descriptions

• Analyse de sentiment

• Extraction automatique de caractéristiques

. **Deep Learning :**

• Réseaux de neurones pour relations complexes

• Autoencoders pour réduction de dimension

Optimisation :

• Optuna pour l'optimisation des hyperparamètres

• AutoML (TPOT, Auto-sklearn)

Application mobile :

• Version React Native

• Mode hors ligne